实验四实验报告

实验四实验报告

Spark安装与配置

下载Spark

IDEA安装Scala插件

新建Scala项目

导入Spark的jar包

任务一

1. 统计application_data.csv中贷款金额AMT_CREDIT 的分布情况

思路

全部代码

在Spark WebUI中查看

2. 统计application_data.csv中AMT_CREDIT-AMT_INCOME_TOTAL最高和最低的各十条记录

思路

全部代码

在Spark WebUI中查看

任务二

1. 统计所有男性客户的小孩个数类型占比情况

思路

全部代码

在Spark WebUI查看

2. 统计每个客户每天的平均收入, 并按照从大到小排序

思路

全部代码

在Spark WebUI中查看

任务三

Step1:数据预处理及特征提取 Step2:划分训练集和测试集

Step3:训练模型

Step4:评估模型效果

全部代码:

在Spark WebUI中查看

遇到的困难及解决方法

Spark安装与配置

本次实验的使用的是IDEA+Scala

安装配置的主要参考网站如下:

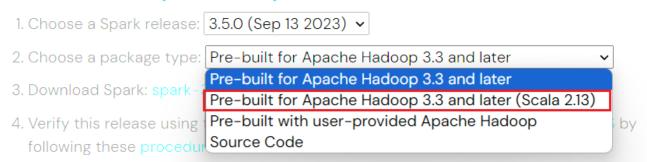
<u>在idea 2021 上 配置本地 scala 2.12 spark 3.0.2 开发环境</u>

解决java.io.FileNotFoundException: HADOOP HOME and hadoop.home.dir are unset.

下载Spark

下载地址: https://spark.apache.org/downloads.html

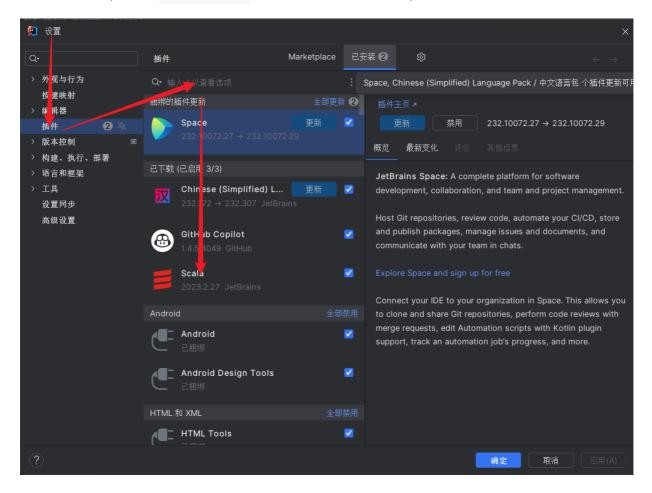
Download Apache Spark™



注意,这里应该选择第二个,也就是(Scala 2.13)。之前在用第一个的时候出了一点bug,但用第二个就好使了

IDEA安装Scala插件

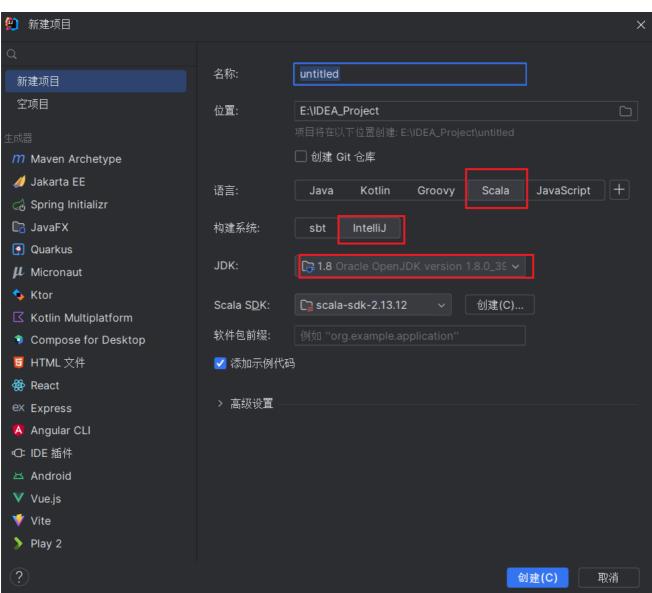
这一步很简单,就在设置──插件中搜索并下载scala即可,然后重新启动



新建Scala项目

Spark运行需要java环境,因为之前已经配好了,所以直接导入即可然后对于Scala SDK,没有下也没关系,直接在创建项目中下载即可。





导入Spark的jar包

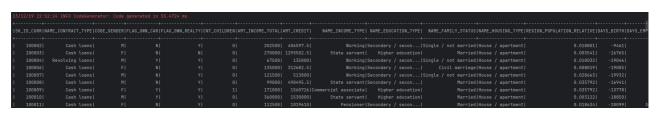
这一步也比较简单: 项目结构→→库→+ 导入下载的Spark文件中的jar目录即可。

任务一

1. 统计application_data.csv中贷款金额AMT_CREDIT 的分布情况

思路

- 1. 首先, 用 local[*] 模式创建一个 SparkSession 对象
- 2.用 spark.read 方法创建一个DataFrameReader对象,读取application_data.csv,读取结果如下图所示:



3. 根据AMT_CREDIT分组

使用 groupby 函数,并在 groupBy 中,使用 floor(col("AMT_CREDIT") / 100 00) * 10000 表达式对 AMT_CREDIT 列的值进行处理,实现按照每一万为一个范围进行分组。

分组结果如下:全部结果可查看附件

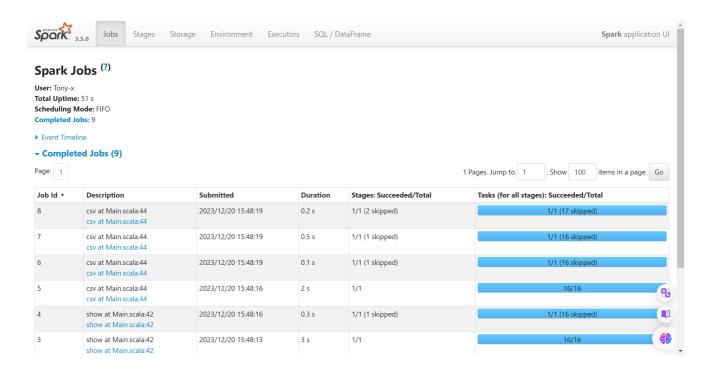
```
|credit_range|credit_range_upper|count
40000
              150000
                                   |561
150000
              160000
                                  1891
160000
              170000
                                  719
170000
              180000
                                  1226
180000
              190000
                                  668
190000
              1100000
                                  1939
1100000
              1110000
                                  1871
1110000
              1120000
                                  |1930 |
120000
              1130000
                                  |1323 |
130000
              140000
                                  |4792 |
1140000
              150000
                                  |2239 |
1150000
              160000
                                  3653
1160000
              1170000
                                   1919
1170000
              1180000
                                   |2131 |
1180000
             190000
                                  18745 l
src > @ Main.scala
```

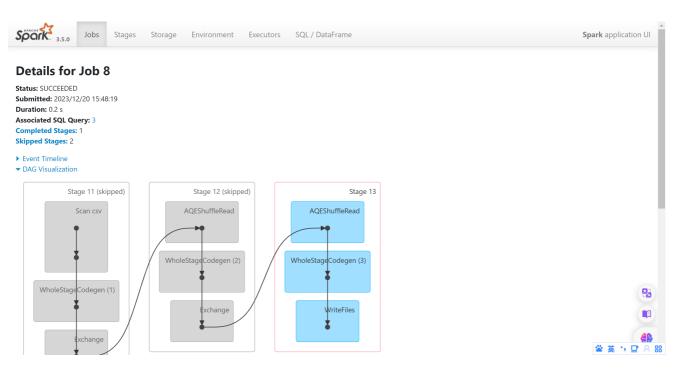
全部代码

```
def Task1_1(df: DataFrame): DataFrame = {
1
2
         // 将AMT_CREDIT列转换为Double类型
3
         val dfWithAmount = df.withColumn("AMT_CREDIT",
     col("AMT_CREDIT").cast("Double"))
4
5
         // 统计 AMT_CREDIT 的分布情况
         val creditDistribution = dfWithAmount.groupBy(
6
7
             floor(col("AMT_CREDIT") / 10000) * 10000 as "credit_range"
           )
8
9
           .count()
           .orderBy("credit_range")
10
         //creditDistribution添加一列, 计算每个区间的上界
11
12
         val creditDistribution1 =
     creditDistribution.withColumn("credit_range_upper",col("credit_range")+100
     00)
13
         //count列和credit_range_upper列交换位置
14
         val df1 =
     creditDistribution1.select("credit_range","credit_range_upper","count")
15
         // 显示结果
```

```
16df1.show(false)17//将其写入csv文件,模式设置为overwrite,保存列名18df1.write.mode(SaveMode.Overwrite).option("header",<br/>"true").csv("E:\\IDEA_Project\\exp4\\src\\output\\Task1_1")19df120}
```

在Spark WebUI中查看





2. 统计application_data.csv中AMT_CREDIT-AMT_INCOME_TOTAL 最高和最低的各十条记录

思路

本题也较为简单, 主要流程如下:

- 1. 获取所需列, 并计算 差值 列
- 2. dataframe排序,取最前面的10个和最后10个
- 3. 输出结果

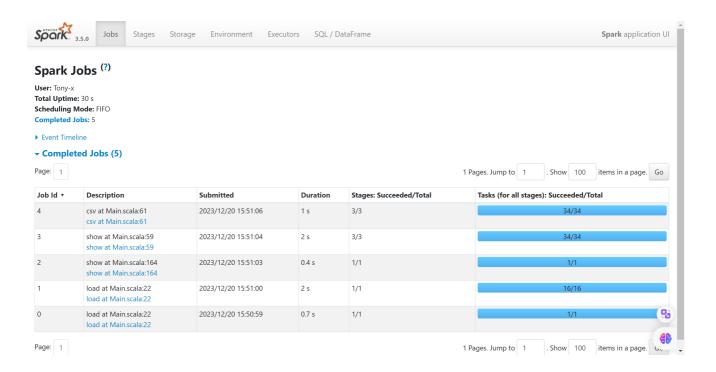
```
|SK_ID_CURR|NAME_CONTRACT_TYPE|AMT_CREDIT|AMT_INCOME_TOTAL|差值
|433294
          |Cash loans
                             14050000
                                       1405000
                                                        |3645000.0
1210956
         |Cash loans
                             |4031032.5 |430650
                                                        3600382.5
434170
         |Cash loans
                             |4050000 |450000
                                                        3600000.0
1315893
         |Cash loans
                             14027680 1458550
                                                        13569130.0
238431
         |Cash loans
                             |3860019 |292050
                                                        |3567969.0
         |Cash loans
                                                        3462750.0
1240007
                             |4050000 |587250
117337
         |Cash loans
                             |4050000 |760846.5
                                                        |3289153.5
120926
         |Cash loans
                             |4050000 |783000
                                                        3267000.0
117085
         |Cash loans
                                                        3206943.0
                             3956274 | 749331
228135
         |Cash loans
                             |4050000 |864900
                                                        |3185100.0
1114967
         |Cash loans
                                                        I-1.16437509E8I
                             1562491
                                        1117000000
1336147
          |Cash loans
                             |675000
                                        118000090
                                                        I-1.732509E7
                                                        I-1.20994965E7|
1385674
         |Cash loans
                             |1400503.5 |13500000
190160
          |Cash loans
                             1431531
                                       9000000
                                                        |-7568469.0
1252084
         |Cash loans
                             1790830
                                       16750000
                                                        1-5959170.0
                                                        1-4050000.0
337151
         |Cash loans
                             450000
                                       4500000
                                                        1-3664620.0
1317748
         |Cash loans
                             835380
                                      4500000
310601
          |Cash loans
                                                        1-3275059.5
                             675000
                                       3950059.5
432980
         |Cash loans
                             |1755000
                                       14500000
                                                        1-2745000.0
157471
          |Cash loans
                             953460
                                        13600000
                                                        1-2646540.0
```

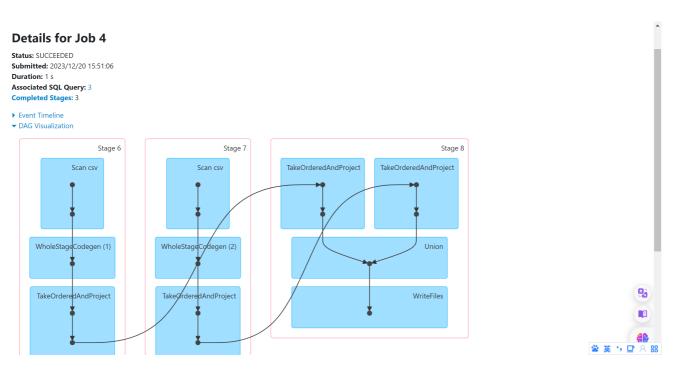
全部代码

```
def Task1_2(df: DataFrame): DataFrame = {
    //选取所需列
    val df1 =
    df.select("SK_ID_CURR","NAME_CONTRACT_TYPE","AMT_CREDIT","AMT_INCOME_TOTAL
    ")
    //添加一列: AMT_CREDIT-AMT_INCOME_TOTAL
    val df2 = df1.withColumn("差值",col("AMT_CREDIT")-
    col("AMT_INCOME_TOTAL"))
```

```
//选取差值最大和最小的10行
6
7
         val df3 = df2.orderBy(col("差值").desc).limit(10)
         val df4 = df2.orderBy(col("差值").asc).limit(10)
8
9
         //将两个DataFrame合并
         val df5 = df3.union(df4)
10
         df5.show(false)
11
12
         //保存结果
         df5.write.mode(SaveMode.Overwrite).option("header",
13
     "true").csv("E:\\IDEA_Project\\exp4\\src\\output\\Task1_2")
         df5
14
     }
15
```

在Spark WebUI中查看





任务二

1. 统计所有男性客户的小孩个数类型占比情况

思路

1. 筛选出所需的列,并用filter函数筛选出男性客户

2. 根据 CNT_CHILDREN 使用 groupby , 并用 count() 求出小孩个数的总数, 升序排序

注意,读取的数据中 CNT_CHILDREN 默认类型是String,所以需要先转换成int类型再进行升序排序

```
|CNT_CHILDREN|count|
10
              |70318|
11
              |22660|
12
              |10413|
|3
              |1446 |
14
              |170 |
15
              33
              111
6
17
              |4
18
              11
19
              11
111
              11
114
              1
```

3. 计算全部男性客户, 并求出不同小孩数的占比

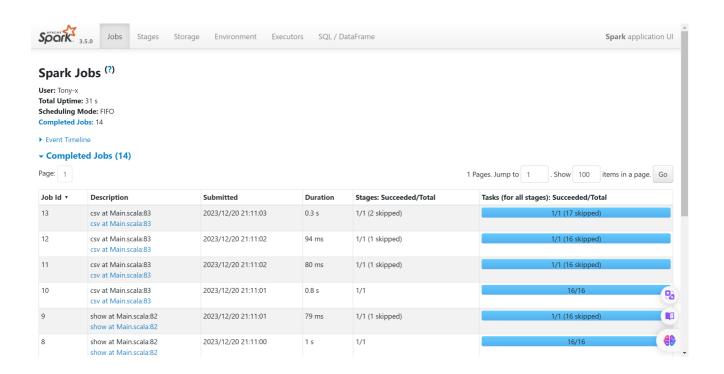
```
|CNT_CHILDREN|count|rate
            |70318|0.6693191444807204
            |22660|0.21568832751120798
            |10413|0.09911573496797038 |
            |1446 |0.013763694685843193 |
            |170 |0.0016181383793868207|
            |33 |3.1410921482214756E-4|
            |11 |1.0470307160738252E-4|
                 |3.807384422086637E-5 |
                 |9.518461055216593E-6 |
            |1
                 |9.518461055216593E-6 |
|11
                 |9.518461055216593E-6 |
114
                  |9.518461055216593E-6 |
```

全部代码

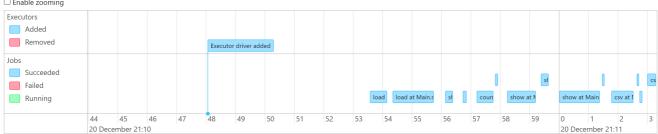
```
def Task2_1(df: DataFrame): DataFrame = {
1
        //统计所有男性客户 (CODE_GENDER = M) 的 小 孩个数 (CNT_CHILDREN) 类型占比情况
2
        val df1 = df.select("CODE_GENDER","CNT_CHILDREN")
3
        //选取df1中CODE_GENDER = M的行
4
        val df2 = df1.filter(col("CODE_GENDER") == "M")
5
        df2.show(false)
6
7
       //计算全部男性个数,也就是df2的行数
        val male_count = df2.count()
8
        //df2根据CNT_CHILDREN分组
```

```
val df3 = df2.groupBy("CNT_CHILDREN").count()
10
         //CNT_CHILDREN转化成Int类型
11
12
         val df4 =
     df3.withColumn("CNT_CHILDREN",col("CNT_CHILDREN").cast("Int"))
          //根据CNT_CHILDREN升序排列
13
         val df5 = df4.orderBy(col("CNT_CHILDREN").asc)
14
15
         df5.show(false)
         //计算每个CNT_CHILDREN的占比
16
         val df6 = df5.withColumn("rate",col("count")/male_count)
17
         df6.show(false)
18
         df6.write.mode(SaveMode.Overwrite).option("header",
19
      "true").csv("E:\\IDEA_Project\\exp4\\src\\output\\Task2_1")
         df6
20
       }
21
```

在Spark WebUI查看







2. 统计每个客户每天的平均收入, 并按照从大到小排序

思路

1. 选取相关列, 并计算平均收入

$$avg_income = \frac{AMT_INCOME_TOTAL}{DAYS_BIRTH}$$

注意,从原始表格中读取的数据出生天数是负数,因此在计算的时候需要给出生天数乘以-1

2. 筛选每日平均收入大于1的客户并倒序排列

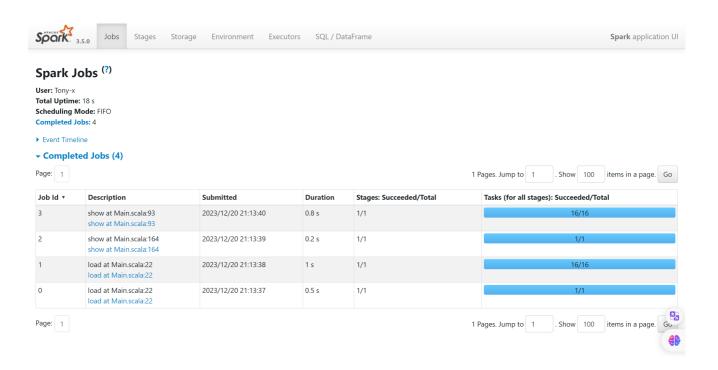
```
df2.filter(col("avg_income") > 1).orderBy(col("avg_income").desc
即可实现
```

+	+	+	+	+
SK_ID_CU	RR AMT_INCOME_T	OTAL DAYS_BIR	TH avg_income	- 1
+	+	+	+	+
114967	117000000	-12615	9274.673008323	425
336147	18000090	-15704	1146.210519612	8375
385674	13500000	-13551	996.2364401151	207
190160	9000000	-16425	547.9452054794	52
219563	4500000	-10778	417.5171645945	4445
310601	3950059.5	-10572	373.6340805902	3834
157471	3600000	-9988	360.4325190228	274
252084	6750000	-19341	348.9995346672	871
199821	3375000	-12516	269.6548418024	928
337151	4500000	-18461	243.7571095823	6283
141198	2025000	-8312	243.6236766121	2704
429258	3600000	-14897	241.6593945089	6153
196091	3375000	-14018	240.7618775859	6092

全部代码

```
def Task2_2(df: DataFrame): DataFrame = {
1
2
         // 选取所需列
         val df1 = df.select("SK_ID_CURR", "AMT_INCOME_TOTAL", "DAYS_BIRTH")
 3
4
         //添加一列: AMT_INCOME_TOTAL/DAYS_BIRTH
5
         val df2 = df1.withColumn("avg_income",
     col("AMT_INCOME_TOTAL").cast("Double") / (-
     col("DAYS_BIRTH").cast("Double")))
         //筛选出avg_income大于1的行并降序排列
6
         val df3 = df2.filter(col("avg_income") >
7
     1).orderBy(col("avg_income").desc)
         df3.show(false)
8
9
         df3
       }
10
```

在Spark WebUI中查看



任务三

根据给定的数据集,基于Spark MLlib 或者Spark ML编写程序对贷款是否违约进行分类,并评估实验结果的准确率。可以训练多个模型,比较模型的表现。

本实验中选取的特征有:

```
"CNT_CHILDREN", "AMT_INCOME_TOTAL", "AMT_CREDIT",
"NAME_CONTRACT_TYPE_index", "DAYS_BIRTH", "DAYS_EMPLOYED",
"DAYS_REGISTRATION", "DAYS_ID_PUBLISH",
"CODE_GENDER_index", "FLAG_OWN_CAR_index", "FLAG_OWN_REALTY_index"
```

Step1:数据预处理及特征提取

在本章节中, 我们会将原数据进行数据预处理, 并以此构造出特征向量。

1. 将String类型的数据编码为数值型数据

由于原数据中的许多数据是String类型的,无法直接作为特征,所以需要先将其编码,这里使用的是 org.apache.spark.ml.feature.StringIndexer 将其转换成数值数据。

```
1
         // 将所需的string类型转换为数值类
 2
         val columnsToIndex = Array("NAME_CONTRACT_TYPE", "CODE_GENDER",
     "FLAG_OWN_CAR", "FLAG_OWN_REALTY", "TARGET") // 列名数组
         val columnsToIndex_output = Array("NAME_CONTRACT_TYPE_index",
 3
     "CODE_GENDER_index", "FLAG_OWN_CAR_index", "FLAG_OWN_REALTY_index",
     "label") // 改变为数值型的数组
 4
         val indexedColumns = columnsToIndex.zip(columnsToIndex_output).map {
     case (colName, output) \Rightarrow
 5
           //遍历上述列,分别构造StringIndexer
 6
           new StringIndexer()
 7
             .setInputCol(colName)
 8
             .setOutputCol(s"${output}")
 9
         }
10
         val indexedDF = indexedColumns.foldLeft(df) { (accDF, indexer) ⇒
           indexer.fit(accDF).transform(accDF)
11
12
         }
```

2. 将所有数值型数据向量化

在将String类型的数据编码成数值型数据后,所有的特征都是数值型数据。下面使用 Spark ML中的 VectorAssembler 构建特征向量。在机器学习中,特征向量是用来描述样本特征的一种形式,它将各个特征组合成一个向量,供机器学习模型使用。

构造后数据如下图所示:

Step2: 划分训练集和测试集

本阶段比较简单,使用下列语句即可。

```
1 | val Array(trainDF, testDF) = preprocessed_df.randomSplit(Array(0.8, 0.2))
```

Step3:训练模型

由于有Spark ML的强大支持,只需要调包并设置参数即可。

```
1
    val dt = new DecisionTreeClassifier()
2
       .setFeaturesCol("features")
       .setLabelCol("label")
3
       .setMaxBins(15)
4
       .setImpurity("gini")
5
6
       .setSeed(10)
7
     // 训练模型
     val dtModel = dt.fit(trainDF)
8
9
     // 在测试集上预测
     val testPredictions = dtModel.transform(testDF)
10
11
     testPredictions
```

- .setMaxBins(15): 指定最大的分箱数。在构建决策树时,数据会根据特征值的范围进行分箱处理。这里设置的最大分箱数为15。
- .setImpurity("gini"): 指定用于分裂节点的不纯度度量方式。在决策树的构建中, "gini" 表示使用基尼不纯度进行分裂, 用来衡量数据的纯度。
- .setSeed(10): 设置随机种子,用于在构建决策树时引入随机性,有助于提高模型的泛化能力。

Step4:评估模型效果

本阶段也比较简单,直接调用 import org.apache.spark.ml.evaluation.MulticlassClassificationEvaluator 即可。

```
1  //计算测试集召回率
2  val evaluator1 = new MulticlassClassificationEvaluator()
3     .setMetricName("weightedRecall")
4  val recall = evaluator1.evaluate(testPredictions)
5  //计算测试集精确率
```

```
6
     val evaluator2 = new MulticlassClassificationEvaluator()
 7
        .setMetricName("weightedPrecision")
 8
     val precision = evaluator2.evaluate(testPredictions)
9
     // 计算测试集F1值
     val evaluator3 = new MulticlassClassificationEvaluator()
10
        .setMetricName("f1")
11
     val f1 = evaluator3.evaluate(testPredictions)
12
     print("recall : " + recall+"\n")
13
     print("precision: " + precision+"\n")
14
15
     print("f1-score : " + f1+"\n")
```

可以看见, 使用决策树的预测贷款是否违约的模型效果如下:

```
recall : 0.9188987127811727

precision: 0.8443748443508963

f1-score : 0.8800619216916292

23/12/20 15:09:40 INFO SparkUI: Stopped Spark web UI at <a href="http://172.27.131.130:4040">http://172.27.131.130:4040</a>
```

全部代码:

定义的函数:

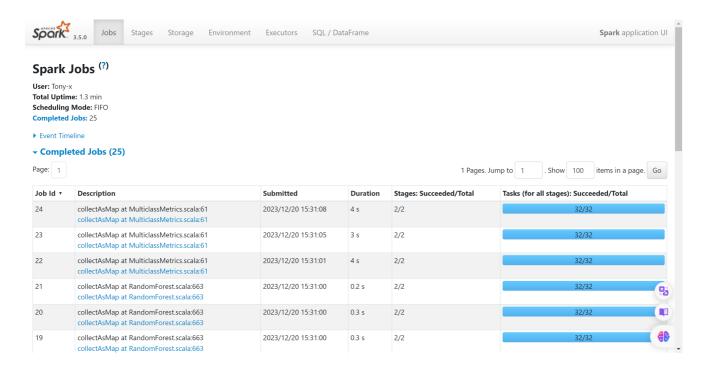
```
1
       def Task3_get_preprocessed_df(df: DataFrame): DataFrame = {
2
         // 将所需的string类型转换为数值类
 3
         val columnsToIndex = Array("NAME_CONTRACT_TYPE", "CODE_GENDER",
     "FLAG_OWN_CAR", "FLAG_OWN_REALTY", "TARGET") // 列名数组,你希望转换的列
 4
         val columnsToIndex_output = Array("NAME_CONTRACT_TYPE_index",
     "CODE_GENDER_index", "FLAG_OWN_CAR_index", "FLAG_OWN_REALTY_index",
     "label")
5
         val indexedColumns = columnsToIndex.zip(columnsToIndex_output).map {
     case (colName, output) \Rightarrow
           new StringIndexer()
6
7
             .setInputCol(colName)
             .setOutputCol(s"${output}")
8
9
         }
10
         val indexedDF = indexedColumns.foldLeft(df) { (accDF, indexer) ⇒
           indexer.fit(accDF).transform(accDF)
11
12
         }
         // 构建特征向量
13
14
         val assembler = new VectorAssembler()
            .setInputCols(Array("CNT_CHILDREN", "AMT_INCOME_TOTAL",
15
     "AMT_CREDIT", "NAME_CONTRACT_TYPE_index", "DAYS_BIRTH", "DAYS_EMPLOYED",
     "DAYS_REGISTRATION", "DAYS_ID_PUBLISH", "CODE_GENDER_index",
16
             "FLAG_OWN_CAR_index", "FLAG_OWN_REALTY_index"))
           .setOutputCol("features")
17
```

```
val assembledDF = assembler.transform(indexedDF)
18
19
         //打印features和label列
20
         assembledDF.select("features", "label").show(false)
21
         assembledDF
       }
22
23
       def Model(trainDF: DataFrame, testDF:DataFrame): DataFrame = {
         // 创建决策树模型
24
         val dt = new DecisionTreeClassifier()
25
           .setFeaturesCol("features")
26
           .setLabelCol("label")
27
28
           .setMaxBins(15)
29
           .setImpurity("gini")
           .setSeed(10)
30
31
         // 创建随机森林模型
     // val rf = new RandomForestClassifier()
32
            .setFeaturesCol("features")
33
     //
             .setLabelCol("label")
34
     //
     //
            .setNumTrees(10)
35
36
     //
             .setMaxBins(10)
37
     //
            .setImpurity("gini")
38
     //
             .setSeed(10)
39
         // 训练模型
40
         val dtModel = dt.fit(trainDF)
41
42
43
         // 在测试集上预测
44
         val testPredictions = dtModel.transform(testDF)
         testPredictions
45
       }
46
       def Evaluate(testPredictions: DataFrame): Unit = {
47
48
         //计算测试集召回率
         val evaluator1 = new MulticlassClassificationEvaluator()
49
50
           .setMetricName("weightedRecall")
         val recall = evaluator1.evaluate(testPredictions)
51
52
         //计算测试集精确率
         val evaluator2 = new MulticlassClassificationEvaluator()
53
            .setMetricName("weightedPrecision")
54
55
         val precision = evaluator2.evaluate(testPredictions)
         //计算测试集F1值
56
57
         val evaluator3 = new MulticlassClassificationEvaluator()
           .setMetricName("f1")
58
59
         val f1 = evaluator3.evaluate(testPredictions)
         print("recall : " + recall+"\n")
60
         print("precision: " + precision+"\n")
61
         print("f1-score : " + f1+"\n")
62
63
       }
```

主函数调用:

```
//Task3
1
2
     //数据预处理
3
     val preprocessed_df=Task3_get_preprocessed_df(df)
     // 随机划分训练集和测试集
 4
     val Array(trainDF, testDF) = preprocessed_df.randomSplit(Array(0.8, 0.2))
5
6
7
     // 训练模型
8
     val testPredictions = Model(trainDF, testDF)
9
     // 评估模型
10
     Evaluate(testPredictions)
```

在Spark WebUI中查看



遇到的困难及解决方法

1.在保存数据时报错: java.io.FileNotFoundException: HADOOP_HOME and hadoop.home.dir are unset.

该问题可能是因为本次实验直接是在本机上跑的,本机上没有安装hadoop,在按照这篇文章 安装hadoop和winutils后问题就解决了。文章链接

2. 关于DataFrame

在读取数据的时候,如果仅仅使用spark.read的话,会默认所有数据都是String类型,但如果加上 .option("header","true") ,就可以让读取的时候自动判别数据类型,减少了后续类型转化工作

3. 关于Spark WebUl

如果用IDEA+Scala,程序在运行完就会立即关闭Spark端口,导致无法访问 localhost:404 0,我们可以在程序运行完毕后等待一会 Thread.sleep(1000000),就可以打开Spark端口 4.关于一个dataframe在写入文件时出现多个csv文件

Spark DataFrame在写入文件时,默认会根据数据的分区(partitions)来生成对应数量的文件,每个分区的数据会被写入一个单独的文件中。这在分布式计算环境下是为了更好地利用集群资源,提高数据的并行处理能力。如果DataFrame有多个分区,写入时就会生成多个文件。

因此可以再写入时添加参数 .coalesce(1) 解决问题